



"Nova" Lei de Improbidade Administrativa - Uma análise jurimétrica

José Luiz Silva Ramos Cavalcanti

Instituto de Matemática e Estatística
(IME-USP)

Dezembro / 2024

Objetivo e Abordagem Jurimétrica

Objetivo: Analisar os impactos da Lei 14.230/21 na aplicação da Lei de Improbidade Administrativa.

Jurimetria: Marcelo Guedes Nunes a define como uma (a) disciplina do conhecimento que (b) utiliza a metodologia estatística para (c) investigar o funcionamento de uma ordem jurídica. (Nunes, 2016).

Estrutura da apresentação

- 1 Direito
- 2 Os Dados
- 3 A modelagem estatística
- 4 Resultados e Conclusões

Improbidade Administrativa

Principal instrumento de combate a corrupção no Brasil, criado pela Lei 8.429/92.

Improbidade Administrativa

Principal instrumento de combate a corrupção no Brasil, criado pela Lei 8.429/92.

Contexto Histórico da Alteração Legal

- Estado judicializado e persecutório, Operação Lava-Jato
- Promulgação da Lei 14.230/21 em 2021, alterando a Lei 8.429/92 em um cenário de reformas anticorrupção.

Mudanças Principais

- Introdução do dolo específico e extinção da modalidade culposa

Mudanças Principais

- Introdução do dolo específico e extinção da modalidade culposa
- Legitimidade exclusiva do Ministério Público na propositura das ações

Caso em Estudo

Para avaliar o impacto das mudanças na Lei de Improbidade, iremos abordar 2 situações:

- Avaliar impactos imediatos nos julgamentos.
- Identificar mudanças na propositura de novas ações.

Estrutura da apresentação

- 1 Direito
- 2 Os Dados
- 3 A modelagem estatística
- 4 Resultados e Conclusões

Base de dados

Dados obtidos junto ao Tribunal de Justiça:

- Resultados dos julgamentos em Segunda Instância, com base na data dos acórdãos proferidos
- Data de entrada das ações de Improbidade Administrativa

LGPD e Filtragem

- Tratamento dos dados (Câmaras anonimizadas, n°s dos processos)
- Seleção de caso mais simples (1 parte envolvida de cada lado)

Dados tratados: Julgamentos

Processo	Classe	Câmara Julgadora	Recorrente	Recorrido	Situação do Provimento	Data Acórdão
...
5619-2019	Apelação e Remessa	Câmara J	Ministério Público	Particular	Não- Provimento	24/09/2019
5622-2019	Apelação	Câmara L	Particular	Ministério Público	Provimento	19/08/2020
5623-2019	Apelação	Câmara E	Particular	Ministério Público	Não- Provimento	05/02/2020
5631-2019	Apelação	Câmara G	Ente Público	Particular	Não- Provimento	06/09/2019
5634-2019	Apelação	Câmara B	Particular	Ministério Público	Provimento	23/08/2019
...

Seleção dos casos

- Provimentos dos recursos dos réus particulares
- Desprovimentos dos recursos do Ministério Público
- Percentual de ações propostas pelo Ministério Público

Análise percentual

Definição da janela de agrupamento de dados:

- Agrupamento mensal sobre os resultados dos julgamentos em Segunda Instância
- Agrupamento quinzenal de novas ações distribuídas

Exemplo da Tabela Percentual

bin	Situação do Provimento	Contagem	Total	Percentual
-2	Não-Provimento	8	13	61.538462
-2	Provimento	5	13	38.461538
-1	Não-Provimento	5	12	41.666667
-1	Provimento	7	12	58.333333
0	Não-Provimento	7	11	63.636364
0	Provimento	4	11	36.363636
1	Não-Provimento	1	5	20.000000
1	Provimento	4	5	80.000000
2	Provimento	1	1	100.000000
3	Não-Provimento	4	7	57.142857
3	Provimento	3	7	42.857143

Figure: Tabela centrada na data de corte com 30 dias de agrupamento para cada bin

Estrutura da apresentação

- 1 Direito
- 2 Os Dados
- 3 A modelagem estatística
- 4 Resultados e Conclusões

Inferência causal

- Idealmente, gostaríamos de comparar o mesmo processo antes do advento das alterações legais com seu resultado após a entrada em vigor da lei
- Porém, só observamos um mesmo indivíduo em uma única situação (antes ou depois da alteração legal, no nosso caso).
- Isso é o que chamamos de problema fundamental da inferência causal

Contrafactual

- A ideia de causalidade, portanto, está intimamente ligada a ideia de contrafactual
- Quando falamos em contrafactual não estamos nos referindo a uma realização passada (ou futura) de uma variável, mas sim a uma realização que não aconteceu (uma espécie de história alternativa)

Modelo de Outcomes Potenciais

- Uma das principais ferramentas para compreender análise causal é o modelo de outcomes potenciais (ou Rubin Causal Model)
- Considere uma variável binária:

$$D_{i,t} = \begin{cases} 1, & \text{se o indivíduo recebe tratamento no instante } t \\ 0, & \text{se não recebe o tratamento no instante } t \end{cases} \quad (1)$$

- Considere uma variável atinente ao resultado:

$$Y_{i,t}^j = \begin{cases} Y_{i,t}^1, & \text{outcome se recebeu o tratamento em } t \\ Y_{i,t}^0, & \text{outcome se não recebeu o tratamento em } t \end{cases} \quad (2)$$

Modelo de Outcomes Potenciais

Resumindo, componentes do Modelo de Outcomes Potenciais:

- 1 Tratamento (D): Indica se a unidade recebeu ou não a intervenção (por exemplo, uma nova lei)
- 2 Outcome (Y): O resultado de interesse (por exemplo, o percentual de absolvições dos réus particulares).
- 3 Outcomes Potenciais ($Y(1)$ e $Y(0)$): Representam os resultados sob tratamento e controle, respectivamente. O efeito causal seria a diferença entre esses dois outcomes.

Outcomes Potenciais

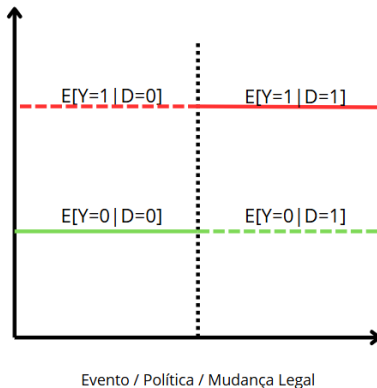


Figure: Outcomes potenciais x Outcomes Realizados

Efeito Médio

O efeito de tratamento para o individuo i é igual a $Y_i^1 - Y_i^0$

- Definimos como o efeito de tratamento médio (ATE) a média do efeito de tratamento em toda a população:

$$ATE = E[Y_i^1] - E[Y_i^0] \quad (3)$$

- Como não existem para a mesma unidade i , não podemos calcular imediatamente o ATE porém, podemos estimá-lo com o uso de algumas técnicas.

Técnicas/Ferramentas de Inferência Causal

Para tentarmos gerar contrafactuais e inferências válidas para demonstrar a causalidade, segundo este framework, temos diversas técnicas:

- Matching (pareamento) - Criar grupos controle parecidos com o grupo tratado para fazer comparação

Técnicas/Ferramentas de Inferência Causal

Para tentarmos gerar contrafactuais e inferências válidas para demonstrar a causalidade, segundo este framework, temos diversas técnicas:

- Matching (pareamento) - Criar grupos controle parecidos com o grupo tratado para fazer comparação
- Experimentos Aleatórios Controlados (RCTs): Considerados o padrão-ouro, onde os participantes são aleatoriamente designados a grupos de tratamento ou controle

Técnicas/Ferramentas de Inferência Causal

Para tentarmos gerar contrafactuais e inferências válidas para demonstrar a causalidade, segundo este framework, temos diversas técnicas:

- Matching (pareamento) - Criar grupos controle parecidos com o grupo tratado para fazer comparação
- Experimentos Aleatórios Controlados (RCTs): Considerados o padrão-ouro, onde os participantes são aleatoriamente designados a grupos de tratamento ou controle
- Variáveis Instrumentais: Não consigo distinguir os efeitos causados por uma variável, uso uma variável auxiliar e na medida dessa variável com minha variável explicadora, tento capturar o efeito da variável independente na variável dependente)

Técnicas/Ferramentas de Inferência Causal

Para tentarmos gerar contrafactuais e inferências válidas para demonstrar a causalidade, segundo este framework, temos diversas técnicas:

- Matching (pareamento) - Criar grupos controle parecidos com o grupo tratado para fazer comparação
- Experimentos Aleatórios Controlados (RCTs): Considerados o padrão-ouro, onde os participantes são aleatoriamente designados a grupos de tratamento ou controle
- Variáveis Instrumentais: Não consigo distinguir os efeitos causados por uma variável, uso uma variável auxiliar e na medida dessa variável com minha variável explicadora, tento capturar o efeito da variável independente na variável dependente)
- Regressão Descontínua que veremos a seguir

Design de Regressão Descontínua (RDD)

Definição:

O Design de Regressão Descontínua é uma técnica quase-experimental usada para identificar efeitos causais quando a atribuição ao tratamento é determinada por um limiar ou ponto de corte.

Como Funciona o RDD:

- 1 Variável Running: Uma variável contínua que determina a elegibilidade para o tratamento (por exemplo, pontuação em um teste, escala de tempo, idade).
- 2 Ponto de Corte: O limiar acima ou abaixo do qual a intervenção é aplicada (data de publicação da lei).
- 3 Comparação: Unidades próximas ao ponto de corte são comparadas, assumindo que são semelhantes em todas as outras características.

Hipótese chave do RDD

Continuidade dos Outcomes Potenciais

$E[Y_i^0|X = c_0]$ e $E[Y_i^1|X = c_0]$ são funções contínuas em X ao redor de c_0

Em suma por essa hipótese dizemos que os outcomes potenciais são contínuos em torno do cutoff, ou seja, se não houvesse a alteração legal o comportamento permaneceria inalterado. Captura-se o efeito local pela observação de um salto no cutoff

Continuidade dos Outcomes e Efeito encontrado




Figure: Continuidade dos Outcomes x Estimação do LATE

Garantindo a hipótese chave

De maneira geral, podemos dividir em duas categorias as preocupações em relação a continuidade dos outcomes potenciais:

- Manipulação da running variable
- Endogeneidade do cutoff (presença de outros tratamentos)

Estimando

Estimar um RDD consiste basicamente em estimar regressões dos dois lados da descontinuidade e "comparar" os resultados no do cutoff.

Como obtemos pelo RDD uma aproximação local, são utilizados para essa estimação observações próximas do cutoff, em uma intervalo ou bandwidth antes e depois do ponto de corte.

Estimando

Estimar um RDD consiste basicamente em estimar regressões dos dois lados da descontinuidade e “comparar” os resultados no do cutoff. Como obtemos pelo RDD uma aproximação local, são

utilizados para essa estimação observações próximas do cutoff, em uma intervalo ou bandwidth antes e depois do ponto de corte.

Escrevendo a nossa equação simplificada para os julgamentos,

temos:

$$Y_b = \beta * D_b + \alpha_A * Z_A + \dots + \alpha_M * Z_M + u_b \quad (4)$$

Estimando

Por fim, nossa equação para as ações distribuídas, temos:

$$J_b = \gamma + \beta * D_b + \varepsilon_b \quad (5)$$

Assim procuramos o β que corresponde ao nosso Efeito Médio de Tratamento Local:

$$\beta = \lim_{X_i \leftarrow c_0} E[Y_i(1)|X_i = c_0] - \lim_{X_i \rightarrow c_0} E[Y_i(0)|X_i = c_0] \quad (6)$$

Estrutura da apresentação

- 1 Direito
- 2 Os Dados
- 3 A modelagem estatística
- 4 Resultados e Conclusões

Recursos dos Réus - Provimentos




Figure: RDD com janela de 30 dias

Resultados 1

Aumento de 9,34% nos provimentos de recursos de Réus-particulares após a nova lei.

Dependent variable:	
	y Percentual de provimentos
D	9.729** (4.227)
Constant	74.154*** (2.093)
Observations	858
R2	0.037
Adjusted R2	0.033
Residual Std. Error	26.257 (df = 854)
F Statistic	10.834*** (df = 3; 854)
Note:	*p<0.1; **p<0.05; ***p<0.01
D = Pós-lei ; Constant = Média antes da lei	

Recursos do Ministério Público - Desprovimentos




Figure: RDD com janela de 30/31 dias

Resultados 2

Crescimento de 7,15% nos desprovimentos de recursos do Ministério Público.

Dependent variable:	
	y
Percentual de Não-provimentos	
D	7.154* (3.979)
Constant	85.819*** (1.946)
Observations	718
R2	0.016
Adjusted R2	0.012
Residual Std. Error	22.620 (df = 714)
F Statistic	3.936*** (df = 3; 714)
Note:	*p<0.1; **p<0.05; ***p<0.01

D = Pós-lei ; Constant = Média antes da lei

Novas Ações Ministério Público




Figure: Percentual de Novas Ações, com RDD de 15 dias

Resultados 3

Percentual de ações do MP subiu de 83% para 96% após a nova legislação.

```
=====
                        Dependent variable:
                        -----
                                y
                        Percentual de provimentos
                        -----
D                                12.713*
                                (7.181)

Constant                        83.360***
                                (2.934)

-----
Observations                    174
R2                              0.070
Adjusted R2                     0.054
Residual Std. Error            16.757 (df = 170)
=====
Note:                          *p<0.1; **p<0.05; ***p<0.01
=====
```

Conclusões

- 1 Impacto imediato e significativo da nova lei observado tanto no que tange aos julgamentos em Segunda Instância quanto a propositura de novas ações


Conclusões


- 1 Impacto imediato e significativo da nova lei observado tanto no que tange aos julgamentos em Segunda Instância quanto a propositura de novas ações
- 2 Quanto a validade externa, resultados podem ser testados e verificados em outros Tribunais de Justiça no Brasil.

Conclusões

- 1 Impacto imediato e significativo da nova lei observado tanto no que tange aos julgamentos em Segunda Instância quanto a propositura de novas ações
- 2 Quanto a validade externa, resultados podem ser testados e verificados em outros Tribunais de Justiça no Brasil.
- 3 Em termos práticos a Lei de Improbidade teve sua atuação reduzida diante das dificuldades de condenação dos réus ímprobos, e tentou-se restringir a atuação da lei com a exclusividade do Ministério Público.

Principais referências

 Cattaneo, M. D., Idrobo, N., Titiunik, R., *A practical introduction to regression discontinuity designs: Foundations*, Cambridge University Press, 2019.

 Paula, J. C. G. D, *Em busca da Inferência Válida: métodos e testes de hipóteses nos estudos legislativos brasileiros.*, Revista Brasileira de Ciência Política, 2018, Volume(26), pp. 273-311.

 Cunningham, S., *Causal inference: The mixtape*, Yale University Press, 2021.

Obrigado pela atenção!

